

再探西蒙斯投资之道：基于隐马尔科夫模型的选股策略研究

报告摘要：

● 传奇的大奖章基金

从 1988 年成立到 2010 年 1 月 1 日西蒙斯正式退休，大奖章基金的净年均收益率超过 35%，远超标普 500 指数的年化收益率。并且，在市场波动较大的时候，比如 2000 年科技股灾和 2008 年的全球金融危机，大奖章基金表现反而更好，当年都获得了 90% 以上的业绩回报。

文艺复兴科技公司的核心成员中，有多位 HMM 领域和语音识别领域的专家，因此人们相信隐马尔科夫模型是大奖章基金取得辉煌业绩的法宝。

● 基于 HMM 模型的选股策略

本报告将语音识别的技术引入到股票涨跌预测中。假设上涨和下跌的股票各自都存在一种明确的模式，都分别可由一个 HMM 模型来描述。我们选择换手率、股价 1 日涨跌幅等 6 个价量指标作为模型观测值，选择股票池内上涨的样本训练表征上涨模式的 HMM 模型。

预测时，一个股票在表征上涨模式的 HMM 模型上的观测概率越大，说明该股票实际上涨的概率也越大。我们将股票池内的股票按照 HMM 因子值均分成 10 档，每期超配最高一档的股票。

● 模型的选股收益远超基准

通过实证分析，基于隐马尔科夫模型的选股策略以中证 500 成份股为股票池，能够获得较高的超额收益。而且在行业中性优化之后，策略的效果进一步提升，在 2007 年 2 月 1 日——2018 年 8 月 15 日的回测区间内，策略年化超额收益率为 16.19%，最大回撤为 -9.69%，信息比达到 2.14。

● 核心假设风险：

本报告提出的基于隐马尔科夫模型的选股策略根据历史数据进行回测，策略模型并非百分百有效，市场结构及交易行为的改变以及类似交易参与者的增多有可能使得策略失效。

图 1 HMM 股票涨跌预测模型预测过程示意图





图 2 基于 HMM 模型的行业中性选股策略（中证 500 指数对冲）



分析师： 罗 军，S0260511010004



020-87579006



lj33@gf.com.cn

分析师： 安宁宁，S0260512020003



0755-23948352



ann@gf.com.cn

分析师： 史庆盛，S0260513070004



02087577060



sqs@gf.com.cn

相关研究：

多因子 ALPHA 系列报告之 2018-04-26

(三十六)——机器学习多

因子动态调仓策略

深度学习新进展：Alpha 因子 2017-07-11

再挖掘

探寻西蒙斯投资之道：基于 2010-06-17

HMM 模型的周择时策略研究

联系人： 童炯潇 020-87572092

tongjiong Xiao@gf.com.cn

目录索引

一、背景介绍	4
1.1 量化投资传奇——詹姆斯·西蒙斯	4
1.2 隐马尔科夫模型（HMM）或是大奖章基金的秘密武器	5
二、隐马尔科夫模型（HMM）简介	6
2.1 隐马尔科夫模型的定义	6
2.2 隐马尔科夫模型的三个基本问题	7
2.3 隐马尔科夫模型在语音识别领域的应用	10
三、基于 HMM 的股票涨跌预测模型	11
3.1 隐马尔科夫模型对股价涨跌的预测原理	11
3.2 模型输入特征的选择和标准化	13
3.3 模型的训练方式和参数选择	14
四、策略与实证分析	16
4.1 策略原理与参数设置	16
4.2 策略实证分析	16
五、总结与讨论	23

图表索引

图 1: 大奖章基金 (Medallion Fund) 历年净回报率	5
图 2: 高斯混合模型示意图	9
图 3: 经典 HMM 语音识别训练过程示意图	11
图 4: 经典 HMM 语音识别过程示意图	11
图 5: HMM 股票涨跌预测模型训练过程示意图	12
图 6: HMM 股票涨跌预测模型预测过程示意图	12
图 7: HMM 股票涨跌预测模型的状态转移示意图	13
图 8: HMM 股票涨跌预测模型的观测概率分布图	13
图 9: HMM 股票涨跌预测模型训练方式示意图	15
图 10: HMM 因子的 IC 序列图	17
图 11: HMM 因子的分档表现	17
图 12: HMM 因子分档累积收益率	18
图 13: 基于 HMM 模型的多空组合净值曲线	19
图 14: 基于 HMM 模型的选股策略净值曲线 (中证 500 指数对冲)	20
图 15: 行业中性的选股策略净值曲线 (中证 500 指数对冲)	22
表 1: 基于 HMM 模型的多空组合收益率统计表	18
表 2: 基于 HMM 模型的多空组合分年度收益统计	19
表 3: 基于 HMM 模型的选股策略收益率统计表 (中证 500 指数对冲)	20
表 4: 基于 HMM 模型的选股策略分年度收益统计 (中证 500 指数对冲)	20
表 5: 行业中性的选股策略收益率统计表 (中证 500 指数对冲)	21
表 6: 行业中性的选股策略分年度收益统计 (中证 500 指数对冲)	22
表 7: 基于 HMM 模型的选股策略的综合表现	23

一、背景介绍

1.1 量化投资传奇——詹姆斯·西蒙斯


在量化投资领域，存在着一位传奇人物——詹姆斯·西蒙斯（James Simons），这位全球最赚钱的对冲基金基金经理，在2018年3月更新的福布斯全球富豪榜上，以200亿美元的身家排名第59位。

与巴菲特的“价值投资”理念不同，作为著名数学家的西蒙斯依靠数学模型管理自己旗下的巨额基金。西蒙斯似乎是为数学而生的，1955年，17岁的西蒙斯考入麻省理工学院数学系，花了3年时间完成本科学业，随后又用了3年时间拿到加州大学伯克利分校的数学博士学位。此后数年，他一直以学术精英的角色做着自己钟爱的数学研究，1974年与著名数学家陈省身一起提出了《典型群和集合不变式》这一开创性理论，并于两年后获得全球几何界的最高荣誉——奥斯瓦尔德·维布伦（Oswald Veblen）奖。然而功成名就之后，西蒙斯在学术研究上遇到了瓶颈，渐渐地开始将越来越多的精力投注到外汇与商品交易市场上。

1978年，西蒙斯成立了林姆若伊基金，采用判断型投资策略，1982年他将投资公司更名为文艺复兴科技（Renaissance Technologies）。基金成立10年间，西蒙斯的投资回报率不错，但是巨大的投资风险让他承受着很大的精神压力，好运不会一直延续，今天的巨额收益可能在明天变得一无所有。因此，在1988年3月，西蒙斯设立了大奖章基金（Medallion Fund），尝试用数学模型代替传统的基本面分析方法，希望将“靠天吃饭”变成“只赚不赔”。大奖章基金开张的第一年，回报率为8.8%，表现尚可；但是第二年年年初，基金遭遇巨大回撤，西蒙斯意识到模型可能出了问题。半年后他做了一个影响深远的决定：将过去模型中有关宏观经济数据的部分完全剔除，只留下技术性数据。此后，大奖章基金变成了一只彻底的、依靠模型的量化对冲基金，这成为它长盛不衰的根本法宝。

大奖章基金的历年回报率如图1所示，除了在成立的第二年有资产净值的减少之外，其余年份都获得了非常高的正回报。从1988年成立到2010年1月1日西蒙斯正式退休，大奖章基金的净年均收益率超过35%，远远超过标准普尔500指数的年化收益率。并且，在市场波动较大的时候，基金的表现反而越好。2000年科技股灾，标普500下跌10.1%，大奖章基金的净回报为98.5%，几乎翻了一番；2008年全球金融危机，各类资产价格全面下滑，大多数对冲基金都亏损，而大奖章基金的净回报率为98.2%。以上这些数据都是在扣除每年固定5%的管理费和22%~44%不等的绩效提成之后的投资净收益。这些几乎优异到神奇的收益表现，使得众多投资者对文艺复兴的投资方法感到非常好奇。

图1: 大奖章基金 (Medallion Fund) 历年净回报率



数据来源: Bloomberg, Wind, 广发证券发展研究中心

1.2 隐马尔科夫模型 (HMM) 或是大奖章基金的秘密武器

这么多年来, 西蒙斯一直对大奖章基金的投资模型讳莫如深, 除了团队核心成员, 没有人知道他们是如何在市场中赚取这么多回报, 也没有任何其他组织和个人能够复制他们的辉煌。人们尝试从复兴公司核心团队的背景来推测大奖章基金辉煌业绩背后的“神秘模型”。

在文艺复兴科技公司的全部员工中, 约有一半是各个领域的顶尖科学家, 包括数学家、物理学家、统计学家甚至密码学家, 而鲜有商学院毕业的学术, 这跟华尔街的基金公司风格差别巨大。

在文艺复兴科技成立初期, 著名的统计学家莱昂纳多·鲍姆 (Leonard Baum) 无疑起到了关键的作用, 功不可没。鲍姆是率先提出隐马尔科夫模型 (Hidden Markov Model, HMM) 的专家之一, 该方法用来描述一个含有未知参数的马尔可夫过程, 在语音识别、生物信息学等领域取得了非常成功的应用。此外, 统计学中著名的鲍姆-威尔斯 (Baum-Welch) 公式也是以这位杰出科学家的名字命名, 它是一种学习隐马尔科夫模型参数的有效方法。西蒙斯本人认为投资和语音识别很相似, 因此曾经把IBM的整个语音实验室的精英挖到文艺复兴公司。基于这些背景, 人们有理由相信隐马尔科夫模型是大奖章基金取得辉煌业绩的神秘法宝。

实际上, 股价预测和语音识别的过程确实有很多相似之处。比如在单词识别过程中, 单词的发音会被分割成一系列连续的“音素” (phone), 最终整段发音被识别为一个什么词是由这段连续的音素序列所决定的。这个场景与股价涨跌预测类似, 即股价上涨或者下跌也是由一系列价量因素的时间序列所推动, 例如在单边上涨的市场行情中, 股价未来一段时间上涨的概率相对来说就比较大。隐马尔科夫模型能够刻画这个动态变化的过程, 从时间序列中挖掘出更多信息, 这是相对于线性回归、SVM或随机森林等统计学习模型的优势。在此前发布的报告《探索西蒙斯投资之道: 基于HMM模型的择时策略研究》中, 我们实证了隐马尔科夫模型被用在指数择时上, 预测准确度和择时策略收益都取得了不错的效果。本报告将进一步探索, 研究如何将隐马尔科夫模型应用到选股策略中, 并实证其效果。

二、隐马尔科夫模型（HMM）简介

2.1 隐马尔科夫模型的定义

隐马尔科夫模型是关于时序的概率模型，描述由一个隐藏的马尔可夫链随机生成不可观测的状态随机序列，再由各个状态生成对应的一个观测而产生观测随机序列的过程。因此，隐马尔科夫模型包含了两个随机序列，一个是不可观测的状态序列（state sequence），每个状态生成一个观测，又组成了另一个观测的随机序列，称为观测序列（observation sequence）。序列的每一个位置，可以看成是一个时刻，序列上位置的前后表示时间上的先后顺序。

隐马尔科夫模型主要有3个要素，分别是初始概率分布、状态转移概率分布和观测概率分布，它的具体形式如下：

模型所有可能的状态的集合为 $Q = \{q_1, q_2, \dots, q_N\}$ ，所有可能的观测的集合为 $V = \{v_1, v_2, \dots, v_M\}$ ，其中， N 表示可能的状态数， M 表示可能的观测数。假设状态序列的长度为 T ，那么状态序列可以表示为 $I = (i_1, i_2, \dots, i_T)$ ，对应的观测序列可表示为 $O = (o_1, o_2, \dots, o_T)$ 。

- 1) 状态转移矩阵 $A = [a_{ij}]_{N \times N}$ 。其中， $a_{ij} = P(i_{t+1} = q_j | i_t = q_i)$ ， $1 \leq i, j \leq N$ ，且满足 $\sum_{j=1}^N a_{ij} = 1, a_{ij} \geq 0$ ，表示时刻 t 处于状态 q_i 的条件下在时刻 $t+1$ 转移到状态 q_j 的概率。
- 2) 观测概率矩阵 $B = [b_j(k)]_{N \times M}$ 。其中， $b_j(k) = P(o_t = v_k | i_t = q_j)$ ， $1 \leq k \leq M, 1 \leq j \leq N$ ，表示在时刻 t 处于状态 j 的条件下生成观测 v_k 的概率。值得注意的是，这里我们假设了观测变量的样本空间和概率分布是离散型的，事实上观测变量也可以为连续型，概率分布也可以是连续的，比如服从高斯分布。
- 3) 系统初始状态概率分布 $\pi_i = P(i_1 = q_i)$ ， $1 \leq i \leq N$ ，表示起始时刻，系统处于各个状态的概率。

隐马尔科夫模型由初始状态概率分布 π ，状态转移概率矩阵 A 和观测概率矩阵 B 决定。其中， π 和 A 决定状态序列， B 决定观测序列，因此隐马尔科夫模型可以表示为 $\lambda = (A, B, \pi)$ 。由定义可知，隐马尔科夫模型作了两个基本假设：

1. 齐次马尔可夫假设，即假设隐藏的马尔可夫链在任意时刻 t 的状态只依赖于其前一时刻的状态，与其他时刻的状态及观测无关，也与时刻 t 无关。

$$P(i_t | i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(i_t | i_{t-1}), \quad t = 1, 2, \dots, T \quad (2-1)$$

2. 观测独立性假设，即假设任意时刻的观测只依赖于该时刻的马尔可夫链的状态，与其他状态及观测无关，也与时刻 t 无关。

$$P(o_t | i_T, O_T, i_{T-1}, \dots, i_{t+1}, o_{t+1}, i_t, o_t, i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(o_t | i_t) \quad (2-2)$$

2.2 隐马尔科夫模型的三个基本问题

将隐马尔科夫模型应用到实际中，有3个基本的问题需要解决：

问题1：概率计算问题。给定模型参数 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，计算在模型下观测到 O 出现的概率 $P(O|\lambda)$ 。

问题2：学习问题。给定观测序列 $O = (o_1, o_2, \dots, o_T)$ ，估计模型参数 $\lambda = (A, B, \pi)$ ，使得在该模型下观测到 O 出现的概率 $P(O|\lambda)$ 最大。即用极大似然估计的方法估计模型的参数。

问题3：预测问题。已知模型参数 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，求对给定观测序列条件概率 $P(O|\lambda)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$ 。即给定观测序列，求最有可能的对应的状态转移序列。

对于隐马尔科夫模型这三个基本问题的求解，产生了对应的算法。

(1) 前向—后向算法，求解概率计算问题

给定模型参数 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，计算在模型下观测到 O 出现的概率 $P(O|\lambda)$ ，最直接的方法是列举所有可能的长度为 T 的状态转移序列 $I = (i_1, i_2, \dots, i_T)$ ，然后求各个状态序列与观测序列的联合概率 $P(O, I|\lambda)$ ，最后对所有可能的状态序列求和得到 $P(O|\lambda)$ 。这个方法的优点是直观，但是计算量十分巨大，是 $O(TN^T)$ 阶数，会随状态数 N 和序列长度 T 的增长而爆炸。

前向—后向算法优化了概率计算问题的求解，可将计算量优化到 $O(TN^2)$ 。前向算法首先定义前向概率，即到时刻 t 部分观测序列为 $o_1, o_2, \dots, o_t$ 且状态为 q_i 的概率为：

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda) \quad (2-3)$$

可以根据递推前向概率 $\alpha_t(i)$ 得到观测序列概率 $P(O|\lambda)$ 。具体过程如下：

1) 初始化

$$\alpha_1(i) = \pi_i b_i(o_1), \quad 1 \leq i \leq N \quad (2-4)$$

2) 递推，对 $t = 1, 2, \dots, T-1$

$$\alpha_{t+1}(i) = [\sum_{j=1}^N \alpha_t(j) a_{ji}] b_i(o_{t+1}), \quad 1 \leq i \leq N \quad (2-5)$$

3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i) \quad (2-6)$$

类似的，后向算法首先定义后向概率，即从时刻 $t+1$ 到 T 的部分观测序列为 $o_{t+1}, o_{t+2}, \dots, o_T$ 且状态为 q_i 的概率为：

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T, i_t = q_i | \lambda) \quad (2-7)$$

可以根据递推前向概率 $\beta_t(i)$ 得到观测序列概率 $P(O|\lambda)$ 。具体过程如下：

1) 初始化

$$\beta_T(i) = 1, \quad 1 \leq i \leq N \quad (2-8)$$

2) 递推，对 $t = T-1, T-2, \dots, 1$

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad 1 \leq i \leq N \quad (2-9)$$

3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i) \quad (2-10)$$

根据前向概率和后向概率的定义，可以将观测序列概率 $P(O|\lambda)$ 统一写成

$$P(O|\lambda) = \sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad t = 1, 2, \dots, T-1 \quad (2-11)$$

(2) Baum—Welch算法，求解模型学习问题

Baum是文艺复兴科技早期核心成员之一，他是著名的统计学家，也是研究隐马尔科夫模型的大师。Baum—Welch算法是用来解决HMM模型的训练问题，即学习模型参数。给定观测序列 $O = (o_1, o_2, \dots, o_T)$ ，而没有对应的状态序列，目标是学习隐马尔科夫模型的参数 $\lambda = (A, B, \pi)$ ，使得在该模型下观测到 O 出现的概率 $P(O|\lambda)$ 最大。如果我们将状态序列看作不可观测的隐数据 I ，那么隐马尔科夫模型事实上是一个含有隐变量的概率模型，观测序列概率可表示为

$$P(O|\lambda) = \sum_I P(O|I, \lambda) P(I|\lambda) \quad (2-12)$$

模型参数学习可以利用递推的思想，由EM算法实现。我们首先定义两个概率：

a) 给定模型参数 λ 和观测序列 O ，在时刻 t 处于状态 q_i 的概率，记为

$$\gamma_t(i) = P(i_t = q_i | O, \lambda) = \frac{P(i_t = q_i, O | \lambda)}{P(O | \lambda)} \quad (2-13)$$

由前向概率和后向概率的定义可得

$$\alpha_t(i) \beta_t(i) = P(i_t = q_i, O | \lambda) \quad (2-14)$$

于是得到

$$\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{P(O | \lambda)} = \frac{\alpha_t(i) \beta_t(i)}{\sum_{j=1}^N \alpha_t(j) \beta_t(j)} \quad (2-15)$$

b) 给定模型参数 λ 和观测序列 O ，在时刻 t 处于状态 q_i ，且在时刻 $t+1$ 处于状态 q_j 的概率，记为

$$\xi_t(i, j) = P(i_t = q_i, i_{t+1} = q_j | O, \lambda) \quad (2-16)$$

同样可通过前向后向概率计算得到

$$\xi_t(i, j) = \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)} \quad (2-17)$$

具体求解的过程这里不再赘述，通过Baum-Welch算法求得的模型参数估计公式为

$$\pi_i = \gamma_1(i) \quad (2-18)$$

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad (2-19)$$

$$b_j(k) = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \quad (2-20)$$


以上推导过程中，我们假设 $b_j(k) = P(o_t = v_k | i_t = q_j), 1 \leq k \leq M, 1 \leq j \leq N$ 服从离散分布，而实际应用中，假设 $b_j(k)$ 服从连续分布往往能取得更好的效果，此

时的模型被称为连续隐马尔科夫模型。通常情况下，我们假设观测概率，即在时刻 t 处于状态 j 的条件下生成观测 v 的概率服从高斯混合分布 (Gaussian mixture model)，其密度函数为

$$b_j(k) = P(o_t = v | i_t = q_j) = \sum_{m=1}^M \omega_{jm} N(o_t, \mu_{jm}, \Sigma_{jm}) \quad (2-21)$$

其中， M 表示高斯混合模型的分模型数量， $\omega_{jm} > 0$, $\sum_{m=1}^M \omega_{jm} = 1$ ，由3个分模型组成的高斯混合模型的密度函数如图2所示。这样，观测变量的样本空间是连续的，对于连续隐马尔科夫模型，不存在一个确定的观测概率矩阵，与它对应的是高斯混合模型的参数。

图2：高斯混合模型示意图



数据来源：广发证券发展研究中心

(3) 维特比算法 (Viterbi) 算法，求解模型预测问题

维特比算法是用动态规划的思想求解最优路径，即已知模型参数 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，求对给定观测序列条件概率 $P(O|\lambda)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$ 。

首先定义：在时刻 t 状态为 i 的所有单个路径 $(i_1, i_2, \dots, i_t)$ 中概率最大值为

$$\delta_t(i) = \max_{i_1, i_2, \dots, i_{t-1}} P(i_t = i, i_{t-1}, \dots, i_1, o_t, \dots, o_1 | \lambda), \quad 1 \leq i \leq N \quad (2-22)$$

定义在时刻 t 状态为 i 的所有单个路径 $(i_1, i_2, \dots, i_{t-1}, i)$ 中概率最大的路径的第 $t-1$ 个节点为

$$\psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad 1 \leq i \leq N \quad (2-23)$$

维特比算法具体求解步骤如下：

1) 初始化

$$\delta_1(i) = \pi_i b_i(o_1), \quad 1 \leq i \leq N \quad (2-24)$$

$$\psi_1(i) = 0, \quad 1 \leq i \leq N \quad (2-25)$$

2) 递推， $t = 2, 3, \dots, T$

$$\delta_t(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_i(o_t), \quad 1 \leq i \leq N \quad (2-26)$$

$$\psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad 1 \leq i \leq N \quad (2-27)$$

3) 终止

$$P^* = \max_{1 \leq i \leq N} \delta_T(i) \quad (2-28)$$

$$i_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)] \quad (2-29)$$

4) 最优路径回溯，对 $t = T - 1, T - 2, \dots, 1$

$$i_t^* = \psi_{t+1}(i_{t+1}^*) \quad (2-30)$$

最终得到最优路径，即使给定观测序列条件概率 $P(O|\lambda)$ 最大的状态序列


$$I^* = (i_1^*, i_2^*, \dots, i_T^*)$$

2.3 隐马尔科夫模型在语音识别领域的应用

从80年代开始，语音识别的研究逐渐从传统的技术思路转向统计模型，而隐马尔科夫模型的应用实现了语音识别领域的重大突破。著名投资人李开复博士在卡内基梅隆大学实现了第一个基于隐马尔科夫模型的大词汇量语音识别系统Sphinx。

詹姆斯·西蒙斯认为投资和语音识别有很多相似之处，本报告尝试将经典的语音识别模型引入股票涨跌预测问题中。经典的HMM语音识别训练过程如图3所示，语音识别时获取的观测（observation）是一段波形信号（waveform）。首先将波形切分成等长的小片段（frame），对每个frame提取特征（如MFCC），这样每个观测实例就可以用一段特征序列 $X = (x_1, x_2, \dots, x_T)$, $x_i \in R^D$ 来表示，其中T表示序列的长度， x_i 表示从每个frame中提取的特征向量，维度为D。在孤立词识别系统中，对每个词设计一个HMM模型，通过训练样本不断迭代，最终得到局部最优的参数估计。


图3：经典HMM语音识别训练过程示意图



数据来源：广发证券发展研究中心

训练完模型以后，在识别单词时，同样对语音提取特征，输入每个HMM模型中，采用前向-后向算法求出每个HMM模型生成该序列的概率。最后取最大概率对应的模型，而该模型所对应的单词就是识别的结果。

图4：经典HMM语音识别过程示意图



数据来源：广发证券发展研究中心

三、基于 HMM 的股票涨跌预测模型


3.1 隐马尔科夫模型对股价涨跌的预测原理

启发于HMM模型在语音识别中的应用，我们尝试将其思想引入到股票涨跌预测中。本报告提出的策略基于以下两个核心假设：

- 1) 按照之前一段时间（周或月）股价走势，涨和跌的股票各自都存在一种明确的模式与其对应，都分别可由一个HMM模型（UP模型和DOWN模型）来描述；
- 2) 股票的外在数据表现（如涨跌幅、换手率等）可由有限个服从马尔可夫过程的隐状态所决定，且满足齐次马尔可夫假设和观测独立性假设。


基于以上两个核心假设，本报告将通过隐马尔科夫模型来预测个股未来一段时间股价的涨跌。首先，假设持仓期为 L 天，我们的目标是，在交易日 T ，去预测 $(T+L)$ 日个股股价相对于 T 日的涨跌。假设观测序列长度为 Q ，那么将每个股票的价格信息切分成日频的观测序列，每一日的价格信息向量（如1日涨跌幅、换手率）对应语音识别模型中的frame，取 $(T-Q+1) \sim T$ 日的价格信息向量，获得长度为 Q 的观测序列，对应语音识别模型中的waveform。模型训练时，我们选择 $(T+L)$ 日股价相对 T 日上涨的股票作为UP模型的训练样本，选择 $(T+L)$ 日股价相对于 T 日下跌的股票作为DOWN模型的训练样本。实际预测时，在 T 日，我们分别将每个股票在 $(T-Q+1) \sim T$ 日的价格信息向量作为特征输入训练好的UP模型和DOWN模型中，求得不同模型下观测到该观测序列的概率 P_{UP} 和 P_{DOWN} ，如果 $P_{UP} > P_{DOWN}$ ，则说明该观测序列由UP模型生成的概率更大，该股票在 $(T+L)$ 日相对于 T 日上涨的概率大于下跌的概率；反之，则认为该股票下跌的概率大于上涨的概率。HMM股票涨跌预测模型的训练和预测过程分别如图5和图6所示。

图5：HMM股票涨跌预测模型训练过程示意图



数据来源：广发证券发展研究中心

图6：HMM股票涨跌预测模型预测过程示意图




数据来源：广发证券发展研究中心

我们以一个简化的例子来说明具体预测的过程。假设我们只取每日的换手率作为特征，即特征维度为1，取序列长度 $Q=2$ ；HMM模型的隐含状态数为2，记为 q_1 和 q_2 ，每个状态对应的高斯混合模型的分模型数为3。某个训练好的HMM模型的状态转移矩阵如图7所示，模型的初始状态为 q_1 ；每个状态对应的高斯混合模型如图8所示。

有一个待预测的个股，观测序列为 $O=\{0.8, 0.4\}$ ，那么可能的状态序列为 $I = \{q_1, q_2\}$ 和 $I = \{q_1, q_1\}$ 。在该HMM模型下，观测到此序列的概率为


$$P(O|\lambda) = 1 * 0.7 * (0.4 * 0.3 + 0.6 * 0.2) = 0.168 \quad (3-1)$$

图7：HMM股票涨跌预测模型的状态转移示意图



数据来源：广发证券发展研究中心

图8：HMM股票涨跌预测模型的观测概率分布图



数据来源：广发证券发展研究中心

对每一个待预测的个股，分别求UP模型和DOWN模型下生成该股票对应的观测序列的概率 P_{UP} 和 P_{DOWN} ，如果 $P_{UP} > P_{DOWN}$ ，则说明该观测序列由UP模型生成的概率更大，该股票在 $(T+L)$ 日相对于T日上涨的概率大于下跌的概率；反之，则认为该股票下跌的概率大于上涨的概率。

3.2 模型输入特征的选择和标准化

本报告主要从个股的价量信息中选取特征，作为HMM模型的观测值。观测向量维度为6，可表示为

$$o_t = \left(\frac{close-open}{open}, \frac{high-open}{open}, \frac{open-low}{open}, turnover, returnPast1d, cap \right) \quad (3-2)$$

其中，close、open、high、low分别表示每日股票的收盘价、开盘价、最高价和最低价；turnover表示每日换手率；returnPast1d表示每日收盘价相对于前日收盘价的涨跌幅；cap表示每日收盘时的流通市值。这7个因子我们称之为原始股票因子，观测向量的每个分量我们称之为特征。

股票的原始因子数据中存在一些缺失值和异常值，且不同因子值之间取值范围相差巨大，因此我们需要对这些特征作标准化处理。本报告中对特征标准化的过程分为以下几个环节：

1) 缺失值处理

当股票某一期的因子值（如流通市值）缺失时，用上一期的因子值替代。

2) 极值、异常值处理

当股票因子数据显著偏离同期其他股票因子数据时，我们设置边界阈值进行处理。我们令上边界为同期股票因子值的均值加上3倍标准差，即

$up = E(x) + 3std(x)$ ；下边界为同期股票因子值的均值减去3倍标准差，即

$up = E(x) + 3std(x)$ 。当股票因子值高于上边界时，用上边界值代替；当股票因子值低于下边界时，用下边界值代替。这样，可以使得股票因子的取值都在上下边界之间。

3) 沿截面的特征标准化

本报告采用z-score方法对各个特征（观测值）进行标准化。假设在时刻 t ，某股票 k 对应的第 i 个特征取值为 $x_{t,k}^i$ ，z-score标准化把变量处理成均值为0，方差为1：

$$\tilde{x}_{t,k}^i = \frac{x_{t,k}^i - E[x_t^i]}{std[x_t^i]}$$

其中， $E[x_t^i]$ 和 $std[x_t^i]$ 分别表示该时刻所有样本池内股票的第 i 个特征取值的均值和标准差。


3.3 模型的训练方式和参数选择

在本报告中，我们选择的调仓周期 L 为5个交易日，HMM模型也选择以5个交易日为预测周期，即在 T 交易日收盘时，预测5个交易日之后，股价相对于 T 交易日收盘价的涨跌情况。股票池为中证500成份股，所有的训练样本和测试样本都从中证500成份股内选择。为使模型能够更好的跟踪市场风格的变化，本报告选择以完全滚动的方式训练模型，即每次调仓时都重新训练模型。同时在足够的训练样本和计算复杂度上取一个折中，往前推10个周期的样本作为训练集，模型观测序列的长度为 Q ，这是模型待确定的一个超参数。如图9所示，在 T 交易日，我们的目标是预测每个成份股在 $T+5$ 交易日相对于当前股价的涨跌情况，假设观测序列长度取 $Q=10$ ，测试集内每个个股的观测序列为 $(T-9) \sim T$ 交易日共10天的观测值，每一天共有6个观测值，详见公式3-2。

每期调仓时，训练集的构造方式如下：

- 1) 在T交易日，选择相对于(T-5)交易日股价上涨的股票作为UP模型的样本，股价下跌的股票作为DOWN模型的样本，观测序列是(T-14)~(T-5)日之间长度为10天的观测值，每天同样是6个观测值；
- 2) 按照1)中的方式往前再推9个周期，总共获得大约 $500 \times 10 = 5000$ 个训练样本，按照涨跌幅分成正负两类，分别训练UP模型和DOWN模型。

图9：HMM股票涨跌预测模型训练方式示意图



数据来源：广发证券发展研究中心

我们以2007年2月1日，相对于5天前涨幅为正的中证500成份股为测试集，并根据以上描述的方式构造训练集来确定隐马尔科夫模型（UP 模型）的参数。我们首先在合理范围内筛选各个超参数的可能取值，然后用网格搜索的方法在训练集上训练模型，最后选择使测试集上样本平均观测概率最大的超参数组合，确定为：

- 1) 隐藏状态数， $N=3$
- 2) 观测序列长度， $Q=10$
- 3) 高斯混合模型的分模型数， $M=2$

四、策略与实证分析

4.1 策略原理与参数设置

我们此前假设股票的涨和跌各自都存在一种明确的模式与其对应，通过上涨的股票数据训练得到的UP模型能够表征股票“涨”这一种模式。因此，本报告的选股策略基于这样一个主要逻辑，即在UP模型下，某个成份股的观测序列概率 $P(O|\lambda_{UP})$ 越大，说明该股票的观测序列由UP模型生成的概率越大，那么它未来上涨的概率也越大。在这种逻辑下，由UP模型计算得到的个股观测序列概率就类似传统的选股因子，如EP，ROE等。为方便描述，我们以下称这个观测序列概率为HMM因子。

本报告以中证500指数成份股为股票池进行选股策略的回测，回测参数设置如下：

调仓周期：5个交易日

股票池：中证500成份股，剔除ST股票，剔除交易日停牌的股票

超配组合：调仓时将股票池按照HMM因子大小均分成10档，等权买入最高一档的个股

对冲方案：多空对冲；中证500指数对冲

回测期：2007年2月1日——2018年8月15日

交易成本：多空对冲时不考虑交易成本；指数对冲时取千分之二的交易成本


调仓规则：为了控制策略的换手率，防止产生过高的交易成本，在每次调仓时，优先选入已持有的股票。具体规则是，将中证500成份股按照HMM因子值均分成十档，最高的一档得10分，第二档得9分，以此类推，最后一档得1分；调仓时，上期持有的股票在原始因子得分基础上上调15%，再根据最终得分选择股票池内股票数目十分之一的个股买入，得分相同时优先选择HMM因子值较大的。这么做的效果是保证上期持有的、本期得分在9分以上的股票得以优先保留（ $9 \times 1.15 > 10$ ），减少换仓的交易成本。

4.2 策略实证分析

4.2.1 HMM因子的历史IC和分档收益率实证分析

因子IC是指截面因子值与个股下期收益率之间的相关系数，能够反映因子提供超额收益的能力。2007年2月1日以来，将HMM因子与未来5个交易日的收益率求截面的秩相关系数，得到HMM因子的IC序列如图10所示，IC平均值为0.082，标准差为0.135。


图10: HMM因子的IC序列图



数据来源: Wind, 广发证券发展研究中心


以5个交易日为调仓周期, 在每个调仓日, 将中证500成份股按HMM因子大小分成10档, 2007年2月以来的分档表现如图11所示, 每档的累积收益率如图12所示。

图11: HMM因子的分档表现



数据来源: Wind, 广发证券发展研究中心

图12: HMM因子分档累积收益率



数据来源：广发证券发展研究中心

由以上两个图可以看出，HMM因子值大的股票整体上表现要优于因子值小的股票，该因子的单调性较好。

4.2.2 多空对冲策略实证分析


假设可以卖空最低档（第十档）的股票，买入第一档的股票，多空组合自2007年2月以来的净值如图13所示，收益统计如表1所示。不考虑交易成本，多空组合年化收益率达到48.68%，最大回撤为-15.74%，调仓胜率为66.96%。多空对冲策略分年度表现如表2所示，除了市场风格变化较大的2017年之外，策略在其他年份都获得了不错的回报。

表1: 基于HMM模型的多空组合收益率统计表

组合	累积收益率	年化收益率	波动率	信息比	最大回撤	胜率
多空	9202.96%	48.68%	16.93%	2.88	-15.74%	66.96%
多头	2289.53%	32.01%	35.54%	0.90	-64.10%	58.75%
中证 500	122.83%	7.26%	33.64%	0.22	-71.72%	56.07%

数据来源：Wind，广发证券发展研究中心

图13: 基于HMM模型的多空组合净值曲线



数据来源：广发证券发展研究中心

表2: 基于HMM模型的多空组合分年度收益统计

年度	超额收益率	超额年化收益率	波动率	信息比	最大回撤	胜率
2007	95.88%	110.83%	18.47%	6.00	-7.32%	79.55%
2008	59.02%	59.02%	21.85%	2.70	-8.43%	59.18%
2009	118.99%	118.99%	16.81%	7.08	-7.63%	83.67%
2010	16.75%	16.75%	15.18%	1.10	-10.19%	60.42%
2011	41.29%	41.29%	12.25%	3.37	-6.64%	71.43%
2012	32.69%	32.69%	11.79%	2.77	-3.06%	63.27%
2013	24.01%	24.01%	17.92%	1.34	-10.43%	65.96%
2014	19.88%	19.88%	15.33%	1.30	-13.95%	63.27%
2015	151.90%	151.90%	23.16%	6.56	-8.53%	79.59%
2016	52.39%	52.39%	14.28%	3.67	-5.51%	61.22%
2017	-1.26%	-1.26%	12.86%	-0.10	-7.54%	55.10%
2018	8.34%	14.71%	14.07%	1.05	-4.42%	57.14%

数据来源：Wind，广发证券发展研究中心

4.2.3 中证500指数对冲实证分析（非行业中性）


以中证500指数为对冲标的，基于HMM模型的选股策略的表现如图14所示，在中证500成份内的年化超额收益率为14.82%，最大回撤为-19.94%，超额胜率为59.11%，信息比为1.78。策略分年度表现如表4所示，在2007年~2016年期间，策略每年都获得了正收益，但是2017年以后表现不佳。（注：2007年数据从2007年2月1日开始；2018年数据截止到2018年8月15日。）

表3：基于HMM模型的选股策略收益率统计表（中证500指数对冲）

组合	累积收益率	年化收益率	波动率	信息比	最大回撤	胜率	平均换手率
指数对冲	401.46%	14.82%	8.33%	1.78	-19.94%	59.11%	32.88%
多头	983.23%	22.66%	35.33%	0.64	-63.75%	58.39%	32.88%
中证 500	122.83%	7.26%	23.79%	0.31	-71.72%	56.07%	-

数据来源：Wind，广发证券发展研究中心

图14：基于HMM模型的选股策略净值曲线（中证500指数对冲）



数据来源：广发证券发展研究中心

表4：基于HMM模型的选股策略分年度收益统计（中证500指数对冲）

年度	超额收益率	超额年化收益率	波动率	信息比	最大回撤	胜率
2007	38.39%	43.39%	9.81%	4.42	-3.49%	77.27%
2008	39.03%	39.03%	9.97%	3.91	-3.52%	65.31%
2009	49.02%	49.02%	7.79%	6.30	-1.64%	75.51%
2010	4.04%	4.04%	7.62%	0.53	-5.35%	50.00%
2011	12.38%	12.38%	6.91%	1.79	-5.58%	61.22%
2012	1.95%	1.95%	5.17%	0.38	-5.87%	51.02%
2013	4.62%	4.62%	7.82%	0.59	-6.90%	53.19%
2014	1.18%	1.18%	6.84%	0.17	-6.00%	51.02%
2015	43.62%	43.62%	13.27%	3.29	-5.36%	67.35%
2016	13.98%	13.98%	5.36%	2.61	-3.02%	67.35%
2017	-10.74%	-10.74%	4.94%	-2.17	-10.96%	42.86%
2018	-6.18%	-10.36%	6.14%	-1.69	-8.86%	39.29%

数据来源：Wind，广发证券发展研究中心

4.2.4 中证500指数对冲实证分析（行业中性）

从4.2.3节的统计可以看出，非行业中性的选股策略回撤较大，且在2017年以后表现不佳，我们考虑通过行业中性的方式进行优化。具体策略如下：

- 1) 计算调仓时，各申万一级行业在中证500指数内的市值占比，作为每个行业分配的总权重 w_i ， $1 \leq i \leq 28$ ；
- 2) 假设未来一期持仓的股票数为 N （股票池内股票数的10%），那么平均每个个股所占权重为 $1/N$ ，每个行业所分配的股票数为 $s_i = \max(1, \text{round}(w_i * N))$ ， $\text{round}()$ 表示四舍五入。如果 $w_i = 0$ ，那么 $s_i = 0$ ，即该行业不选股；如果 s_i 大于该行业在股票池内可选股票数目，则 s_i 调整为该行业在股票池内可选股票数目；
- 3) 在每个行业内，根据HMM因子得分，从高到底选择 s_i 个股票，等权买入，每个股票所占权重为 w_i/s_i 。


基于HMM模型的行业中性的选股策略的表现如图15所示，在中证500成份内的年化超额收益率为16.19%，最大回撤为-9.69%，超额胜率为63.39%，信息比为2.14。策略分年度表现如表6所示，除了2017年之外，策略每年都获得了正收益，整体表现相对非行业中性策略有明显提升。（注：2007年数据从2007年2月1日开始；2018年数据截止到2018年8月15日。）

表5：行业中性的选股策略收益率统计表（中证500指数对冲）

组合	累积收益率	年化收益率	波动率	信息比	最大回撤	胜率	平均换手率
指数对冲	455.40%	16.19%	7.57%	2.14	-9.69%	63.39%	31.48%
多头	1071.94%	24.03%	35.74%	0.67	-65.01%	59.11%	31.48%
中证 500	122.83%	7.26%	23.79%	0.31	-71.72%	56.07%	-

数据来源：Wind，广发证券发展研究中心

图15: 行业中性的选股策略净值曲线 (中证500指数对冲)



数据来源：广发证券发展研究中心

表6: 行业中性的选股策略分年度收益统计 (中证500指数对冲)

年度	超额收益率	超额年化收益率	波动率	信息比	最大回撤	胜率
2007	41.27%	46.71%	8.98%	5.20	-3.64%	79.55%
2008	34.73%	34.73%	8.37%	4.15	-3.09%	67.35%
2009	36.60%	36.60%	7.00%	5.23	-2.55%	77.55%
2010	4.64%	4.64%	6.71%	0.69	-5.02%	60.42%
2011	11.85%	11.85%	6.99%	1.70	-5.01%	59.18%
2012	2.99%	2.99%	5.09%	0.59	-5.71%	57.14%
2013	4.32%	4.32%	6.53%	0.66	-6.21%	61.70%
2014	13.50%	13.50%	5.60%	2.41	-3.66%	69.39%
2015	43.03%	43.03%	13.38%	3.22	-5.03%	67.35%
2016	10.12%	10.12%	3.61%	2.80	-1.54%	63.27%
2017	-7.71%	-7.71%	4.78%	-1.61	-8.30%	38.78%
2018	2.19%	3.79%	5.69%	0.67	-3.53%	57.14%

数据来源：Wind，广发证券发展研究中心

整体来看，基于HMM模型的选股策略的综合表现如表7所示，策略在超过11年的回测期内，获得了显著的超额收益。特别的，行业中性的HMM选股策略在提高超额收益率的同时，能更好地对冲市场风险，降低最大回撤。

表7：基于HMM模型的选股策略的综合表现

策略	多空对冲	非行业中性	行业中性
对冲标的	最低档股票	中证 500 指数	中证 500 指数
累积收益率	9202.96%	401.46%	455.40%
年化收益率	48.68%	14.82%	16.19%
波动率	16.93%	8.33%	7.57%
信息比	2.88	1.78	2.14
最大回撤	-15.74%	-19.94%	-9.69%
胜率	66.96%	59.11%	63.39%
平均换手率	50.12%	32.88%	31.48%

数据来源：Wind，广发证券发展研究中心

五、总结与讨论

隐马尔科夫模型是大奖章基金辉煌业绩背后的秘密武器之一，受此启发，本报告将隐马尔科夫模型引入到投资领域，运用语音识别的技术来预测股票涨跌。假设涨和跌的股票各自都存在一种明确的模式，都分别可由一个HMM模型来描述，那么如果一个股票在表征上涨模式的HMM模型上的观测概率越大，说明该股票实际上涨的概率也越大。

HMM因子具有良好的提供超额收益的能力，IC的平均值为0.082，大多数时候为正值。而且在回测期内，HMM因子值大的股票整体上表现要优于因子值小的股票，按因子值分档的累积收益率具有很好的单调性。基于HMM因子的多空组合年化收益率达到48.68%，最大回撤为-15.74%。

本报告通过实证表明，基于隐马尔科夫模型的选股策略以中证500成份股为股票池，能够获得较高的超额收益。而且在行业中性优化之后，策略的效果进一步提升，年化超额收益率为16.19%，最大回撤为-9.69%，信息比达到2.14。

风险提示

策略模型并非百分百有效，市场结构及交易行为的改变以及类似交易参与者的增多有可能使得策略失效。

广发证券—行业投资评级说明

- 买入： 预期未来 12 个月内，股价表现强于大盘 10%以上。
- 持有： 预期未来 12 个月内，股价相对大盘的变动幅度介于-10%~+10%。
- 卖出： 预期未来 12 个月内，股价表现弱于大盘 10%以上。

广发证券—公司投资评级说明

- 买入： 预期未来 12 个月内，股价表现强于大盘 15%以上。
- 谨慎增持： 预期未来 12 个月内，股价表现强于大盘 5%-15%。
- 持有： 预期未来 12 个月内，股价相对大盘的变动幅度介于-5%~+5%。
- 卖出： 预期未来 12 个月内，股价表现弱于大盘 5%以上。

联系我们

	广州市	深圳市	北京市	上海市
地址	广州市天河区林和西路 9 号耀中广场 A 座 1401	深圳福田区益田路 6001 号 太平金融大厦 31 层	北京市西城区月坛北街 2 号 月坛大厦 18 层	上海浦东新区世纪大道 8 号 国金中心一期 16 层
邮政编码	510620	518000	100045	200120
客服邮箱	gfyf@gf.com.cn			

免责声明

广发证券股份有限公司（以下简称“广发证券”）具备证券投资咨询业务资格。本报告只发送给广发证券重点客户，不对外公开发布，只有接收客户才可以使用，且对于接收客户而言具有相关保密义务。广发证券并不因相关人员通过其他途径收到或阅读本报告而视其为广发证券的客户。本报告的内容、观点或建议并未考虑个别客户的特定状况，不应被视为对特定客户关于特定证券或金融工具的投资建议。本报告发送给某客户是基于该客户被认为有能力独立评估投资风险、独立行使投资决策并独立承担相应风险。

本报告所载资料的来源及观点的出处皆被广发证券股份有限公司认为可靠，但广发证券不对其准确性或完整性做出任何保证。报告内容仅供参考，报告中的信息或所表达观点不构成所涉证券买卖的出价或询价。广发证券不对因使用本报告的内容而引致的损失承担任何责任，除非法律法规有明确规定。客户不应以本报告取代其独立判断或仅根据本报告做出决策。

广发证券可发出其它与本报告所载信息不一致及有不同结论的报告。本报告反映研究人员的不同观点、见解及分析方法，并不代表广发证券或其附属机构的立场。报告所载资料、意见及推测仅反映研究人员于发出本报告当日的判断，可随时更改且不予通告。

本报告旨在发送给广发证券的特定客户及其它专业人士。未经广发证券事先书面许可，任何机构或个人不得以任何形式翻版、复制、刊登、转载和引用，否则由此造成的一切不良后果及法律责任由私自翻版、复制、刊登、转载和引用者承担。